

딥러닝실습 기말 프로젝트 최종 보고서

Learning Environment Adaptive Model 기반 집중도 파악 AI 개발 프로젝트

LEAM : Learning Environment Adaptive Model

2026.06.21

소프트웨어융합대학 인공지능학과

21012030

김지오

목 차

목 차.....	2
1. 프로젝트 개요.....	5
1.1 개발 배경.....	5
1.2 프로젝트 목표	5
1.3 핵심 아이디어 — Learning Environment Adaptive Model.....	6
1.4 중간 보고서 이후 진행 요약	6
2. 기존 연구와 시스템의 한계점	7
2.1 기존 연구 소개.....	7
2.2 다양한 접근 방식 검토 요약	8
2.3 기존 연구의 공통 한계와 본 시스템의 방향.....	8
3. 전체 시스템 아키텍처.....	10
3.1 설계 원칙과 하이브리드 처리 구조.....	10
3.2 매 프레임의 데이터 흐름.....	10
3.3 기술 스택과 통신 프로토콜.....	10
3.4 시스템 아키텍처.....	11
4. 프로젝트 파일 구조.....	12
5. 개발 및 테스트 환경.....	13
5.1 하드웨어	13
5.2 소프트웨어 스택.....	13
6. 입력 데이터·전처리·적용 모델 및 전이학습 결과.....	14

6.1 입력 데이터와 전처리.....	14
6.2 졸음·하품 판정 — EAR / MAR.....	14
6.3 시선 추정 — L2CS-Net.....	14
6.4 휴대폰 탐지 — YOLOv8n 듀얼 모델.....	16
6.5 환경을 분류 — PANNs CNN10.....	20
7. 단계별 세부 설명 및 알고리즘.....	24
7.1 집중 모드 실행과 초기 Calibration.....	24
7.2 학습환경 적응 — I-DT, KDE, 연결요소.....	25
7.3 실시간 집중도 파악 — 계층적 판단 모델.....	26
7.4 종료 및 결과 리포트.....	28
8. 임계값 및 파라미터 결정 근거.....	29
8.1 졸음·하품 관련 임계값.....	29
8.2 캘리브레이션·적응 시간.....	29
8.3 학습 Zone(KDE) 파라미터.....	29
8.4 시선 이탈·휴대폰 판정 파라미터.....	30
9. 성능 평가 체계 및 가중치 결정.....	31
9.1 환경 적응 종합 성능 E와 가중치 α	31
9.2 실시간 집중도 종합 성능 rtC와 가중치 β	32
10. 성능 평가.....	33
10.1 환경 적응도 평가.....	33
10.2 실시간 집중도 평가.....	36

11. 사용자 시나리오 및 검증 계획.....	37
12. 향후 개선 과제.....	37
12.1 휴대폰 탐지의 사각지대 한계.....	38
12.2 의미 있는 말소리의 양면성.....	38
12.3 동적 학습 Zone 생성.....	38
12.4 LLM 기반 자연어 결과 리포트.....	38
12.5 이어폰·귀마개 착용 Edge Case.....	38
12.6 학습 이벤트 소리 분류.....	39
12.7 실측 기반 종합 성능 검증.....	39
13. 프로젝트 마무리.....	40
13.1 기대 효과 및 활용 방안.....	40
13.2 느낀점 및 마무리.....	41
14. 참고문헌.....	43

1. 프로젝트 개요

1.1 개발 배경

최근 학습 관리 애플리케이션과 온라인 기반 공동 학습 문화가 확산되면서 학습자의 집중력 관리와 동기부여에 대한 관심이 높아지고 있다. 대표적으로 열품타와 같은 공부 시간 기록 애플리케이션은 많은 학생들이 사용하는 대표적인 자기관리 도구로 자리 잡았으며, 웹캠을 활용한 온라인 스터디 또한 꾸준히 활용되고 있다. 이와 함께 YouTube 의 “Study With Me” 콘텐츠, 카페에서 공부하는 이른바 “카공” 문화, SNS 를 통한 공부 인증 콘텐츠 역시 지속적으로 증가하고 있다.

이러한 현상은 단순히 공부 장소나 기록 방식의 변화로 보기 어렵다. 공통적으로 혼자 공부하더라도 타인과 함께 공부하는 듯한 분위기를 조성하거나, 외부의 시선과 규칙성을 통해 집중력을 유지하고 학습 동기를 얻으려는 수요가 반영된 결과라고 볼 수 있다. 실제로 많은 학습자들은 혼자 공부할 때보다 누군가와 함께 있는 환경에서 더 높은 긴장감과 몰입감을 느끼며, 이를 위해 별도로 스터디를 구성하거나 카페와 같은 외부 공간을 찾기도 한다.[1]

그러나 이러한 방식에는 현실적인 한계도 존재한다. 웹캠 스터디의 경우 참여자 간 일정 조율이 필요하며, 생활 패턴이 불규칙한 사용자에게는 지속적인 참여가 어렵다. 또한 카메라를 켜고 학습하는 것에 부담을 느끼는 사용자도 적지 않다. 열품타와 같은 기존 서비스는 공부 시간을 측정하는 데에는 효과적이지만, 실제로 사용자가 얼마나 집중했는지까지는 분석하지 못한다는 한계가 있다.

따라서 별도의 타인 참여 없이도 혼자 학습하는 사용자가 자신의 집중 상태를 객관적으로 확인하고, 학습 종료 후 피드백까지 받을 수 있는 지능형 집중도 분석 시스템의 필요성이 제기된다.

1.2 프로젝트 목표

본 프로젝트는 사용자의 실시간 웹캠 영상 및 오디오 입력 데이터를 활용하여 학습 중 집중 상태를 분석하고, 학습 종료 후 결과를 정량화하여 사용자에게 제공하는 AI 기반 집중도 평가 시스템 개발을 목표로 한다. 기존의 단순 시간 측정 중심 학습 관리 도구와 달리, 사용자의 실제 학습 환경과 행동 패턴을 함께 고려하여 보다 현실적인 집중도 판단을 수행하고자 한다.

이를 위해 시스템은 학습 시작 시 사용자의 주변 환경과 학습 도구의 위치를 우선적으로 파악하고, 이후 사용자의 얼굴, 줄음, 휴대폰, 시선, 주변 소음 등을 종합적으로 분석한다. 특히 사용자마다 학습 도구를 놓는 위치나 학습 장소인 학습 환경이 서로 다르다는 점을 반영하여, 환경에 따라 평가 기준을 적응적으로 변경하는 구조를 적용하고자 한다.

최종적으로는 학습 세션 종료 후 집중도, 집중 유지 시간, 비집중 패턴 분석 결과 등을 사용자에게 제공함으로써 자기주도 학습 능력 향상과 집중 습관 개선에 도움을 주는 것을 목표로 한다.

1.3 핵심 아이디어 — Learning Environment Adaptive Model

본 시스템의 핵심 차별점은 '사용자 환경을 먼저 이해한 뒤 집중도를 평가한다'는 점이다. 기존 시스템이 모든 사용자에게 동일한 임계값(예: 정면 응시 여부)을 적용한 것과 달리, 본 시스템은 초기 적응 단계에서 사용자가 자주 응시하는 영역을 '학습 Zone'으로 학습하고 주변 소음 환경을 분류하여 개인화된 기준선을 수립한다. 이후의 모든 집중도 판정은 이 개인화된 기준에 따라 수행되며, 이로써 노트북 화면을 보는 사용자와 독서대의 책을 보는 사용자처럼 서로 다른 학습 자세·도구 배치를 자연스럽게 포용할 수 있다.

1.4 중간 보고서 이후 진행 요약

중간 보고서(계획서)에서 제시한 설계를 실제 동작하는 시스템으로 구현하였으며, 구현 과정에서 다수의 핵심 모듈을 계획서 대비 더 정교한 방식으로 개선하였다. 시선 추적은 동공 위치 휴리스틱에서 학습 기반 시선 추정 모델인 L2CS-Net 으로 교체하였고, 학습 Zone 생성 방식은 K-Means 군집화에서 응시(fixation) 기반 커널 밀도 추정(KDE)으로 전환하였다. 또한 휴대폰 탐지와 환경을 분류에 대해 각각 AI Hub-DCASE 데이터를 활용한 전이학습을 수행하였으며, 개인별 시선 원점 보정과 사용자 중심의 모드 분리(집중 모드·개발자 모드) UI 를 새로 도입하였다.

2. 기존 연구와 시스템의 한계점

2.1 기존 연구 소개

웹캠, 시선 추적 기술, 얼굴 행동 분석 등을 활용하여 사람의 집중도와 주의 상태를 파악하려는 연구는 오래전부터 HCI(Human-Computer Interaction), 교육공학, 학습분석(Learning Analytics), 컴퓨터 비전 분야에서 지속적으로 수행되어 왔다. 특히 별도의 고가 장비 없이 일반 웹캠만으로 사용자의 시선과 얼굴 움직임을 추정할 수 있게 되면서, 온라인 학습 환경에서 집중도 분석에 대한 연구가 활발히 진행되고 있다.

대표적으로 Robal 등은 온라인 학습 환경(MOOC)에서 웹캠 기반 시선 추적 기술을 활용하여 학습자의 주의 상태를 추정할 수 있음을 제시하였다. 해당 연구는 브라우저 기반 시선 추적 프레임워크를 활용하여 별도의 전용 장비 없이도 학습자의 시선 데이터를 수집할 수 있음을 보였다. 이는 원격 학습 환경에서 집중도 분석의 가능성을 보여준 초기 사례로 평가된다.[2]

또한 Hutt 등은 웹캠 기반 eye-tracking 데이터를 활용하여 학습 중 mind wandering(떠돌이 생각, 주의 이탈) 상태와 읽기 이해도를 예측할 수 있음을 보고하였다. 이는 시선 데이터가 단순 응시 위치를 넘어 인지적 상태 추정에도 활용될 수 있음을 보여준다.[3]

국내에서도 웹 기반 실시간 원격 교육 환경에서 학습자의 시선 추적을 통해 집중도를 분석하는 시스템 개발 연구가 진행되었으며, 일반 웹카메라만을 이용한 저비용 시선 추적 기술 연구도 보고되었다. 이러한 연구들은 웹캠만으로도 학습자의 시선 행동을 분석할 수 있다는 실용적 가능성을 제시하였다.[4][5]

한편 기존에도 학습자의 행동 데이터와 히스토리 정보를 활용하여 온라인 학습을 지원하려는 연구가 진행되었다. 이문환 외(2021)는 녹화 영상 기반 수업에서 학습자의 시청 이력과 행동 데이터를 활용하여 자기 감시 및 학습 관리를 지원하는 시스템을 제안하였다. 이는 학습자 상태 데이터를 교육 지원에 활용했다는 점에서 본 연구와 유사한 방향성을 가진다.[6]

산업계에서는 Tobii 와 같은 기업들이 eye tracking 기술을 활용하여 사용자의 주의 집중, 인지 부하(cognitive load), 의사결정 과정 등을 분석하는 솔루션을 제공하고 있다. 이는 시선 정보가 인간의 집중 상태 및 인지 상태를 이해하는 중요한 단서가 될 수 있음을 보여준다.[7]

2.2 다양한 접근 방식 검토 요약

LEAM 구조에 도달하기까지 다섯 가지 접근을 검토하였으며, 각각의 기대 효과와 한계는 다음과 같다. 세부 내용은 중간 보고서에서 소개하였으므로 최종 보고서에서는 요약된 형태의 표로 정리하고자 한다.

접근 방식	기대 효과	한계 및 기각 사유
생체데이터(EEG/ECG/HRV)	집중을 직접·객관적으로 측정	고가 장비, 실시간 연동 난이도, 낮은 접근성 → 비현실적
규칙 기반 행동 분류	구현 단순, 빠른 결과	행동-집중 관계 설명 곤란, Edge Case 취약, 차별성 부족
행동 감점제 점수화	직관적 수치화, 설명 가능	감점 가중치 근거 부족, 사용자 납득 어려움
시선 이탈 + 수동 모드 선택	구현 단순, 모드별 기준 분리	수동 전환의 UX 저해, 독서대 측면 응시 오판, 멍 때림 구분 불가
영상 단일 vs 멀티모달	오디오 추가 시 판단 정확도 향상	학습용 독백은 방해가 아님 → 오디오는 보조 모달리티로 한정

이러한 검토의 결론으로, 사용자 환경을 먼저 이해한 뒤 개인화된 기준으로 집중도를 평가하고 영상에 오디오를 보조적으로 결합하는 LEAM 구조에 도달하였다. 특히 무관한 말소리 효과(Irrelevant Speech Effect)[9]에 근거하여 의미가 담긴 말소리가 집중을 저해한다는 점을 오디오 판정의 핵심 근거로 채택하였다.

2.3 기존 연구의 공통 한계와 본 시스템의 방향

1. 디스플레이 중심 환경이 전제되는 상황에서 기존 연구는 책 읽기 · 필기 · 독서대 사용 등 학습의 다양성을 반영하지 못했다. 본 시스템은 학습 Zone 으로 개인 학습 환경을 학습하여 이를 집중도 측정에 반영하고자 한다.
2. 기존 연구는 정면 응시·시선 이탈 횟수 등 단일 지표에 의존하는 방식이었다. 이에 대한 결과로 시선이 아래로 향하는 경우 독서 활동과 졸음이 혼동되는 상황이 발생한다. 본 시스템은 이러한 차이를 반영하여 계층적 판단 모델을 도입하여 이러한 다양한 학습 상황과 집중 방해 요소들을 순차적으로 판단하고자 한다.
3. 사용자별로 학습 태도가 차이 남에도 불구하고 기존 연구는 동일한 임계값 적용하여 집중도를 판단하고자 하였다. 이러한 연구는 집중도 분석의 결과에 대한 일반화에 있어

한계점을 보이며 신뢰성 확보에도 문제점이 드러난다. 본 시스템은 이러한 환경의 차이를 반영하여 시스템 초기에 캘리브레이션 단계를 도입하고 이렇게 조정된 기준을 기반으로 개인화된 측정을 하여 측정 결과에 대한 신뢰성을 확보하고자 한다.

4. 집중도를 이진화 시키거나 단일 점수로 제시하는 방식은 학습에서의 행동 복잡성이 충분히 설명되지 않는 결과값이라고 판단하였다. 본 시스템은 이러한 행동 복잡성을 고려하여 계층적 판단 모델을 도입하고 각 행동에 대해 적절한 가중치를 두고 최종적으로 네가지 등급(A/B/C/F)으로 결과를 내고, 감점 누적 방식으로 정량화 하고자 하였다.

3. 전체 시스템 아키텍처

3.1 설계 원칙과 하이브리드 처리 구조

본 시스템은 실시간성과 제한된 연산 자원을 동시에 만족하기 위해 처리를 클라이언트(브라우저)와 서버로 분담하는 하이브리드 구조를 채택하였다. 가벼운 연산은 클라이언트에서 즉시 수행하여 프레임당 지연을 최소화하고, GPU 가 필요한 무거운 딥러닝 추론만 서버로 분리하여 단일 GPU 환경에서도 동작 가능하도록 하였다. 구체적으로 클라이언트에서는 MediaPipe Face Mesh 로 얼굴 478 개 랜드마크를 실시간 추출하고 이를 바탕으로 EAR/MAR(줄음·하품)와 고개 각도(Head Pose)를 계산하며, 학습 Zone 히트맵과 시선 포인트를 캔버스에 시각화한다. 서버에서는 시선 추정(L2CS-Net), 휴대폰 탐지(YOLOv8n 듀얼 모델), 환경을 분류(PANNS CNN10)와 같이 GPU 추론이 필요한 모델을 실행한다. 클라이언트와 서버는 WebSocket 으로 양방향 연결되어 특징값·얼굴 크롭·프레임·오디오를 주고받고 집중도 등급을 실시간으로 수신한다.

3.2 매 프레임의 데이터 흐름

웹캠과 마이크로부터 입력이 들어오면 브라우저가 먼저 MediaPipe 로 랜드마크를 추출하고 EAR/MAR/Head Pose 를 계산한다. 동시에 시선 추정을 위해 얼굴 영역을 잘라낸 이미지를 약 0.2 초 간격으로 서버에 전송하고, 휴대폰 탐지를 위해 전체 프레임을 약 0.8 초 간격으로 전송한다. 서버는 L2CS-Net 으로 시선 각도를, YOLOv8 듀얼 모델로 휴대폰 존재 여부를 추론하여 클라이언트로 회신하며, 클라이언트는 이 결과와 자신이 계산한 특징을 묶어 계층적 판단 모델에 전달하고 그 결과로 집중도 등급을 화면에 갱신한다.

```
[웹캠/마이크] → 브라우저(MediaPipe Face Mesh → 랜드마크 → EAR/MAR/HeadPose)
├─ 얼굴 크롭(JPEG) —WebSocket→ 서버 L2CS-Net → yaw/pitch
├─ 전체 프레임(JPEG)—WebSocket→ 서버 YOLOv8 듀얼→ 휴대폰
└─ 특징+오디오 dB —WebSocket→ 서버 계층적 판정 → 등급/점수
```

3.3 기술 스택과 통신 프로토콜

백엔드는 FastAPI(ASGI, Uvicorn)로 구현하였으며 정적 HTML, REST API, WebSocket 을 단일 서버가 모두 제공한다. 딥러닝은 PyTorch 와 Ultralytics YOLOv8, torchaudio 를 사용하고, 세션 데이터는 SQLAlchemy(async)와 SQLite 로 관리한다. 클라이언트는 MediaPipe Face Mesh(CDN)와 HTML5

Canvas, WebRTC(getUserMedia)로 구성된다. WebSocket 메시지는 용도에 따라 구분되며, 그 구조는 아래 표와 같다.

요청 type	내용	응답 type
features	MediaPipe 특징(EAR/MAR/gaze/head)+dB+ 휴대폰	concentration(등급/점수)
gaze	얼굴 크롭 base64	gaze_estimation(yaw/pitch)
frame	전체 프레임 base64	phone_detection(검출/신뢰도/bbox)
readapt	수동 재적응 요청	phase_update(adapting)
phase_check	단계 전환 질의	phase_update(현재 phase)

3.4 시스템 아키텍처

본 시스템의 전체 작동 과정과 데이터 흐름을 한눈에 파악할 수 있도록 Flowchart로 나타내었다. 영상 데이터(CAM)과 오디오 데이터(MIC) 데이터의 수집 및 전처리 단계부터, 각각의 세부 모델(L2CS-Net, YOLOv8n, PANNs 등)이 어떻게 작동하는지 명시하였다. 특히, 초기 보정 단계와 학습 환경 분석 단계, 그리고 4 단계의 계층적 집중도 평가(Hierarchical Decision Model) 로직을 시각화하여, 추상적인 인지 상태가 실시간 데이터와 수식을 통해 어떻게 정량화되는지를 한 눈에 보여준다.




그림 1. LEAM 아키텍처 — 영상 및 오디오 데이터 전처리, 초기 Calibration 및 학습환경 분석(Step 2~3), 그리고 4 단계의 계층적 실시간 집중도 평가 모델(Step 4)을 거쳐 최종 결과가 산출되기까지의 전체 데이터 파이프라인.

4. 프로젝트 파일 구조

시스템은 backend 디렉터리 하위에 FastAPI 애플리케이션(app), 전이학습 스크립트(training), 학습된 가중치(weights)로 구성된다. app 내부는 책임에 따라 모델 래퍼(models), 핵심 로직(services), API 엔드포인트(routers), 데이터 스키마(schemas), 데이터베이스(database)로 분리하였다. 전체 구조는 다음과 같다.

```

backend/
├─ run.py                # 개발 서버 실행 진입점
├─ app/
│  ├─ main.py           # FastAPI 앱·lifespan·모델 로드
│  ├─ config.py         # 임계값·단계 시간 등 전역 설정
│  ├─ models/           # 딥러닝 모델 래퍼
│  │  ├─ gaze_estimator.py # L2CS-Net (시선)
│  │  ├─ phone_detector.py # YOLOv8 듀얼 (휴대폰)
│  │  ├─ audio_classifier.py # PANNs 환경음 분류
│  │  └─ panns_model.py   # CNN10 아키텍처
│  ├─ services/         # 핵심 비즈니스 로직
│  │  ├─ session_manager.py # 세션 생명주기·재적응
│  │  ├─ concentration.py # 계층적 판단 모델
│  │  └─ learning_zone.py # KDE 학습 Zone
│  ├─ routers/          # session / analysis / report
│  ├─ schemas/          # Pydantic 입출력 스키마
│  ├─ database/         # SQLAlchemy 모델
│  └─ static/index.html # 단일 페이지 프론트엔드
├─ training/            # 전이학습·데이터 변환·평가 스크립트
└─ weights/             # 학습된 가중치(.pt/.pth/.pkl)

```

주요 모듈의 역할은 다음과 같다. gaze_estimator.py 는 L2CS-Net 을 래핑하여 얼굴 크롭으로부터 시선 yaw/pitch 를 추론하고, phone_detector.py 는 전이학습 모델과 COCO 사전학습 모델을 함께 실행하는 듀얼 구조를 구현한다. audio_classifier.py 는 PANNs CNN10 백본에 세개의 클래스 분류 헤드를 부착한 환경음 분류기를 로드한다. services 계층의 session_manager.py 는 단계 전환과 재적응을 관리하고, concentration.py 는 계층적 판단과 등급·감점 산정을 담당하며, learning_zone.py 는 응시 기반 KDE 로 학습 Zone 을 생성한다.

5. 개발 및 테스트 환경

5.1 하드웨어

본 시스템의 개발과 실시간 추론, 전이학습은 다음의 단일 데스크톱 환경에서 수행되었다. GPU 는 8GB 메모리의 NVIDIA RTX 4060 으로, 세 가지의 딥러닝 모델(L2CS-Net, YOLOv8n 듀얼, PANNs CNN10)을 동시에 가동하고 실시간 추론을 수행하기 위해 사용된다.

구성요소	사양
OS	Windows 11
CPU	AMD Ryzen 5 7500F
RAM	32 GB DDR5 (5200 MHz)
GPU	NVIDIA GeForce RTX 4060
GPU 메모리	8 GB
GPU 드라이버	591.86
CUDA (PyTorch 빌드)	12.4

5.2 소프트웨어 스택

개발 언어는 Python 3.11(conda 환경 leam)이며, 딥러닝 프레임워크로 PyTorch 와 그 부속 라이브러리를 사용한다. 영상 처리는 클라이언트의 MediaPipe 와 서버의 객체 탐지·이미지 처리 라이브러리로, 오디오 처리는 torchaudio 로 수행한다. 주요 모듈과 용도는 다음과 같다.

분류	모듈 / 라이브러리	용도
서버	FastAPI, Uvicorn, websockets	API·WebSocket 서버
딥러닝	PyTorch, torchvision, torchaudio	모델 추론·전이학습
객체 탐지	Ultralytics YOLOv8	휴대폰 탐지
영상(클라이언트)	MediaPipe Face Mesh, Camera Utils	랜드마크·EAR/MAR/HeadPose
영상(서버)	OpenCV(headless), Pillow, NumPy	이미지 디코딩·전처리
오디오	torchaudio, (librosa, soundfile)	리샘플·log-Mel 변환
수치/과학	NumPy, SciPy(ndimage)	KDE·연결요소·통계
DB/검증	SQLAlchemy, aiosqlite, Pydantic	세션 저장·스키마 검증

6. 입력 데이터·전처리·적용 모델 및 전이학습 결과

6.1 입력 데이터와 전처리

시스템은 별도 센서 없이 일반 웹캠과 마이크로 수집 가능한 영상·오디오를 입력으로 사용한다. 영상에서는 얼굴 검출 여부, 478 개 얼굴 랜드마크, 눈 개폐 상태, 시선 방향과 응시 위치, 고개 회전 각도를 활용한다. 시선 추정을 위해서는 랜드마크 바운딩 박스를 기준으로 얼굴 영역을 잘라 224 픽셀로 인코딩하여 서버로 보내며, 이때 화면이 거울 모드로 표시되므로 좌우 반전을 보정한다. 휴대폰 탐지용 프레임은 640×480 JPEG 로 인코딩한다. 오디오는 16 kHz 단일 채널로 정규화한 뒤 분석 단위를 5 초 클립으로 맞추고, PANNs 내부에서 64 개 멜 빈의 로그-멜 스펙트로그램으로 변환한다.

6.2 졸음·하품 판정 — EAR / MAR

졸음과 하품은 MediaPipe Face Mesh 의 눈·입 주변 랜드마크로부터 계산하는 두 비율로 판정한다. EAR(Eye Aspect Ratio)은 눈의 세로 길이를 가로 길이로 나눈 값으로, 눈을 감을수록 0 에 가까워진다. 본 시스템은 LearnOpenCV 의 표준 6 개의 점 EAR 정의[13]를 그대로 채택하여, 각 눈에 대해 가로 모서리 두 점(P1·P4)과 윗꺼풀·아랫꺼풀 네 점(P2·P3·P5·P6)을 사용한다(좌안 인덱스 362·385·387·263·373·380, 우안 33·160·158·133·153·144). $EAR = (\|P2-P6\| + \|P3-P5\|) / (2 \cdot \|P1-P4\|)$ 로 계산하며, 눈을 뜨면 약 0.3, 감으면 약 0.1 로 떨어져 눈 감김을 안정적으로 검출한다. MAR(Mouth Aspect Ratio)은 입의 세로/가로 비율로 입을 크게 벌릴수록 커진다. EAR 이 임계값(0.21) 이하인 상태가 짧게 지속되면 일반 깜빡임, 일정 시간 이상 지속되면 졸음, 매우 오래 지속되면 수면으로 구분하며, MAR 이 일정 시간 이상 크게 유지되면 하품으로 본다. 각 임계값의 결정 근거는 8 장에서 상세히 설명한다.

6.3 시선 추정 — L2CS-Net

시선 추정에는 ResNet-50 을 백본으로 하는 L2CS-Net 을 사용한다. 이 모델은 얼굴 이미지로부터 시선의 yaw(좌우)와 pitch(상하)를 각각 분류 문제로 풀되, 각 출력 헤드에 Cross-Entropy Loss 와 기댓값(expectation) 기반의 Mean Square Error 를 함께 적용하는 형태의 손실 함수를 사용하여 세밀한 각도 추정을 달성한다. 모델의 전체 구조는 다음 그림과 같다.




그림 2. L2CS-Net 아키텍처 — 얼굴 이미지 → ResNet-50 → FC layers → 제안 손실함수(Cross-Entropy + 기댓값 기반 MSE)로 yaw/pitch 각각 추정 (출처: 디스플레이 중심 안구 움직임 영상 데이터 AI 모델 테스트 결과서)

본 시스템은 '디스플레이 중심 안구 움직임 영상 데이터' 사업에서 학습·검증된 가중치를 그대로 활용한다. 해당 모델의 학습 조건과 검증 환경은 다음과 같다.

항목	내용
백본 / 출력	ResNet-50, yaw-pitch 각 90 개 bin 분류 + 기댓값(softmax) 연속 각도
학습 조건	Epoch 100, batch 16, Optimizer Adam, Early Stopping
데이터셋	전체 2,558,104 장 (Train 80.5% / Val 9.8% / Test 9.8%)
검증 환경	RTX 3090, Ubuntu 18.04, Python 3.10, CUDA 11.6, PyTorch 1.13

시선 추적 성능은 예측 시선 벡터와 정답 시선 벡터 사이의 평균 각도 오차(Mean Angular Error)로 평가하며, 그 결과는 다음과 같다.

항목	내용
목적	시선 각도 추정
지표	Mean Angular Error (MAE)
측정 산식	예측 시선벡터 $\hat{g}$ 와 정답 시선벡터 $\hat{g}$ 사이 평균 각도 오차
성과 목표	$< 10^\circ$
구축 실적	8.8°
달성율	100%

▶ L2CS-Net 시선 추정 테스트 로그

```
root@ec99d1c348cd:/L2CS-Net# python run_valid_l2cs.py
Start testing dataset=nia2022-----
test configuration = gpu_id=cuda:0, batch_size=1, model_arch=ResNet50
```

Starting at: 28/12/2022 21:07:31

test configuration = gpu_id=cuda:0, batch_size=1, model_arch=ResNet50

Start testing dataset=nia2022-----

Iter [1000/250000] This error 7.7360: Mean Angular Error 8.8981

Iter [2000/250000] This error 8.1094: Mean Angular Error 8.8756

Iter [3000/250000] This error 6.9828: Mean Angular Error 8.8349

Iter [4000/250000] This error 9.0864: Mean Angular Error 8.9570

Iter [5000/250000] This error 11.2646: Mean Angular Error 8.9422

Iter [6000/250000] This error 7.7346: Mean Angular Error 8.9462

.....(생략).....

Iter [242000/250000] This error 9.7378: Mean Angular Error 8.8443

Iter [243000/250000] This error 10.6744: Mean Angular Error 8.8437

Iter [244000/250000] This error 7.3994: Mean Angular Error 8.8412

Iter [245000/250000] This error 12.4980: Mean Angular Error 8.8420

Iter [246000/250000] This error 6.4728: Mean Angular Error 8.8388

Iter [247000/250000] This error 6.9296: Mean Angular Error 8.8376

Iter [248000/250000] This error 8.7812: Mean Angular Error 8.8349

Iter [249000/250000] This error 6.5204: Mean Angular Error 8.8356

Iter [250000/250000] This error 4.6018: Mean Angular Error 8.8372

[---nia2022] Total Num:2500000, MAE:8.8372

done at = 28/12/2022 21:30:15

본 시스템은 이 모델의 출력(yaw/pitch)을 캘리브레이션 기반 개인 원점으로 보정한 뒤 화면 좌표로 변환하여 학습 Zone 생성과 시선 이탈 판정에 활용하고자 한다.

6.4 휴대폰 탐지 — YOLOv8n 듀얼 모델

휴대폰 탐지는 두 개의 YOLOv8n 모델을 함께 사용하는 듀얼 구조로 구현하였다. 첫 번째는 AI Hub 데이터로 전이학습한 단일 클래스(cell_phone) 모델로, 화면에서 작게 보이는 원거리 휴대폰에 특화되어 있다. 두 번째는 COCO 로 사전학습된 yolov8n 으로, 손에 들어 화면을 크게 차지하는 근거리 휴대폰을 포착한다. 두 모델 중 하나라도 휴대폰을 탐지하면 검출로 처리하며, 이때 신뢰도는

두 결과 중 최댓값을 사용한다. YOLOv8n 은 CSPDarknet 백본, PAN-FPN 넥, anchor-free Detect Head 로 구성된 단일 단계(one-stage) 객체 탐지기로, 전체 구조와 듀얼 결합 흐름은 다음 그림과 같다.




그림 3. YOLOv8n 듀얼 모델 구조 — 입력 프레임 → Backbone(CSPDarknet) → Neck(PAN-FPN) → Detect Head, 그리고 fine-tuned-COCO 두 모델의 결합

fine-tuned 모델은 소형 데이터에 과적합되어 얼굴 등을 오탐(최대 신뢰도 약 0.56)하는 경향이 있으므로 신뢰도 0.65 이상에서만 인정하고, 오탐이 거의 없는 COCO 모델은 0.40 임계값으로 사용한다. 추가로 짧은 오탐과 깜빡임을 줄이기 위해 클라이언트에서 최근 세 번의 탐지 중 두 번 이상 검출될 때만 '확정'으로 처리하는 시간적 디바운스를 적용하며, 확정 시 탐지 영역(bounding box)을 화면에 오버레이하여 어떤 부분이 휴대폰으로 인식되었는지 시각적으로 제시한다.

학습은 AI Hub 'Small object detection' 데이터에서 전자기기 49 종 중 휴대폰만 추출하여 단일 클래스(cell_phone) 데이터셋을 구성하였다(학습 564 장, 검증 140 장). COCO 사전학습 yolo8n 에서 백본 일부를 동결한 뒤 전이학습을 수행하였고, 과적합 방지를 위해 patience 기반 조기 종료를 적용하여 29 에포크에서 학습이 종료되었다. 검증 집합에 대한 최종 성능은 다음과 같다.

지표	값
mAP@0.5	0.855
mAP@0.5:0.95	0.678
Precision	0.811
Recall	0.804

에포크별 검출 성능(mAP·Precision·Recall)의 진행 상황을 기록한 학습 로그는 아래와 같다.

▶ YOLOv8n 휴대폰 탐지 학습 로그 (에포크별)

Starting training for 50 epochs...							
Epoch	GPU_mem	box_loss	cls_loss	dfl_loss	Instances	Size	
1/50	1.08G	1.073	3.436	0.9383	4	640: 100%	36/36
5.0it/s 7.2s							
	Class	Images	Instances	Box(P	R	mAP50	mAP50-95): 20%
		1/5	1.6it/s	0			
	Class	Images	Instances	Box(P	R	mAP50	mAP50-95): 40%
		1/5	1.6it/s	0			
	Class	Images	Instances	Box(P	R	mAP50	mAP50-95): 60%
		1/5	1.6it/s	0			
	Class	Images	Instances	Box(P	R	mAP50	mAP50-95): 80%
		1/5	1.6it/s	0			
	Class	Images	Instances	Box(P	R	mAP50	mAP50-95): 100%
		1/5	1.6it/s	0			
	all	140	153	0.00321	0.882	0.00976	0.0057
Epoch	GPU_mem	box_loss	cls_loss	dfl_loss	Instances	Size	
2/50	1.24G	1.159	2.335	0.9529	4	640: 100%	36/36
6.7it/s 5.4s							
	Class	Images	Instances	Box(P	R	mAP50	mAP50-95): 20%
		1/5	2.3it/s	0			
	Class	Images	Instances	Box(P	R	mAP50	mAP50-95): 40%
		1/5	2.3it/s	0			
	Class	Images	Instances	Box(P	R	mAP50	mAP50-95): 60%
		1/5	2.3it/s	0			
	Class	Images	Instances	Box(P	R	mAP50	mAP50-95): 80%
		1/5	2.3it/s	0			
	Class	Images	Instances	Box(P	R	mAP50	mAP50-95): 100%
		1/5	2.3it/s	0			
	all	140	153	0.639	0.29	0.402	0.285
Epoch	GPU_mem	box_loss	cls_loss	dfl_loss	Instances	Size	
3/50	1.24G	1.128	1.917	0.9576	4	640: 100%	36/36
7.3it/s 5.0s							
	Class	Images	Instances	Box(P	R	mAP50	mAP50-95): 20%
		1/5	2.3it/s	0			
	Class	Images	Instances	Box(P	R	mAP50	mAP50-95): 40%
		1/5	2.3it/s	0			
	Class	Images	Instances	Box(P	R	mAP50	mAP50-95): 60%
		1/5	2.3it/s	0			
	Class	Images	Instances	Box(P	R	mAP50	mAP50-95): 80%
		1/5	2.3it/s	0			
	Class	Images	Instances	Box(P	R	mAP50	mAP50-95): 100%
		1/5	2.3it/s	0			
	all	140	153	0.881	0.677	0.807	0.542
Epoch	GPU_mem	box_loss	cls_loss	dfl_loss	Instances	Size	
4/50	1.24G	1.144	1.641	0.9654	4	640: 100%	36/36
6.7it/s 5.4s							
	Class	Images	Instances	Box(P	R	mAP50	mAP50-95): 20%

1/5 2.2it/s 0	Class	Images	Instances	Box(P	R	mAP50	
mAP50-95): 40%	2/5 3.9it/s 0	Class	Images	Instances	Box(P		
R mAP50 mAP50-95): 60%	3/5 4.9it/s 0	Class	Images	Instances			
Box(P R mAP50 mAP50-95): 80%	4/5 5.8it/s 0	Class	Images				
Instances Box(P R mAP50 mAP50-95): 100%	5/5 8.4it/s 0.6s						
all 140 153 0.855 0.768 0.854 0.595							
Epoch GPU_mem box_loss cls_loss dfl_loss Instances Size							
5/50 1.24G 1.115 1.472 0.9646 4 640: 100%							36/36
7.2it/s 5.0s							
Class Images Instances Box(P R mAP50 mAP50-95): 20%							
1/5 2.5it/s 0	Class	Images	Instances	Box(P	R	mAP50	
mAP50-95): 40%	2/5 3.9it/s 0	Class	Images	Instances	Box(P		
R mAP50 mAP50-95): 60%	3/5 5.3it/s 0	Class	Images	Instances			
Box(P R mAP50 mAP50-95): 80%	4/5 6.1it/s 0	Class	Images				
Instances Box(P R mAP50 mAP50-95): 100%	5/5 8.9it/s 0.6s						
all 140 153 0.846 0.804 0.87 0.63							
Epoch GPU_mem box_loss cls_loss dfl_loss Instances Size							
6/50 1.24G 1.11 1.304 0.9616 4 640: 100%							36/36
7.1it/s 5.1s							
Class Images Instances Box(P R mAP50 mAP50-95): 20%							
1/5 2.6it/s 0	Class	Images	Instances	Box(P	R	mAP50	
mAP50-95): 40%	2/5 4.4it/s 0	Class	Images	Instances	Box(P		
R mAP50 mAP50-95): 60%	3/5 5.6it/s 0	Class	Images	Instances			
Box(P R mAP50 mAP50-95): 80%	4/5 6.3it/s 0	Class	Images				
Instances Box(P R mAP50 mAP50-95): 100%	5/5 9.3it/s 0.5s						
all 140 153 0.86 0.752 0.85 0.609							
Epoch GPU_mem box_loss cls_loss dfl_loss Instances Size							
7/50 1.24G 1.053 1.103 0.9446 4 640: 100%							36/36
6.7it/s 5.4s							
Class Images Instances Box(P R mAP50 mAP50-95): 20%							
1/5 2.5it/s 0	Class	Images	Instances	Box(P	R	mAP50	
mAP50-95): 40%	2/5 4.4it/s 0	Class	Images	Instances	Box(P		
R mAP50 mAP50-95): 60%	3/5 5.6it/s 0	Class	Images	Instances			
Box(P R mAP50 mAP50-95): 80%	4/5 6.3it/s 0	Class	Images				
Instances Box(P R mAP50 mAP50-95): 100%	5/5 9.4it/s 0.5s						
all 140 153 0.898 0.739 0.858 0.632							
.....(생략).....							

EarlyStopping: Training stopped early as no improvement observed in last 10 epochs. Best results observed at epoch 19, best model saved as best.pt.

To update EarlyStopping(patience=10) pass a new patience value, i.e. `patience=300` or use `patience=0` to disable EarlyStopping.

Model summary (fused): 73 layers, 3,005,843 parameters, 0 gradients, 8.1 GFLOPs

Class Images Instances Box(P R mAP50 mAP50-95): 20%				Class Images Instances Box(P R mAP50 mAP50-95): 40%				Class Images Instances Box(P R mAP50 mAP50-95): 60%				Class Images Instances Box(P R mAP50 mAP50-95): 80%				Class Images Instances Box(P R mAP50 mAP50-95): 100%			
1/5 1.7it/s 0				2/5 2.4it/s 0				3/5 3.0it/s 0				4/5 3.4it/s 0				5/5 5.3it/s 0.9s			
all	140	153	0.811	0.804	0.855	0.678													


Speed: 0.2ms preprocess, 1.9ms inference, 0.0ms loss, 0.9ms postprocess per image

이 데이터셋은 휴대폰이 화면에서 작게 보이는 '소형 객체' 위주이므로, 손에 들어 화면을 크게 차지하는 근거리 휴대폰은 학습 분포 밖이다. 이를 보완하기 위해 운영 시에는 이 전이학습 모델과 COCO 사전학습 모델을 함께 실행하는 듀얼 구조를 채택하였다

6.5 환경음 분류 — PANNs CNN10

환경음 분류에는 AudioSet 으로 사전학습된 PANNs CNN10 을 백본으로 사용한다. 이 모델은 5 초 길이의 16 kHz 파형을 로그-멜 스펙트로그램(64 mel)으로 변환한 뒤 네 개의 합성곱 블록(채널 64→128→256→512)을 거쳐 512 차원 임베딩을 산출하며, 그 위에 512→128→3 구조의 분류 헤드를 부착하여 학습 맥락 3 개 환경(quiet, social_indoor, outdoor)으로 분류하도록 전이학습하였다. 전체 구조는 다음 그림과 같다.

PANNs CNN10 — 환경음 분류 (전이학습)



AudioSet 사전학습 백본(ConvBlock 4개)을 동결 → 분류 헤드 학습 → 10ep 이후 마지막 2개 블록 해제(미세조정).

축 A(환경 유형): 기준 소음 설정용. 축 B(실시간 방해): 말소리·들발음은 AudioSet 주론으로 별도 판정.

그림 4. PANNs CNN10 환경음 분류 구조 — 파형 → Log-Mel → ConvBlock×4 → Global Pooling → 분류 헤드(512→128→3)

위 모델은 로그-멜 스펙트로그램 입력으로 동작하여 실시간 추론에 적합하다. 오디오 분석은 두 축으로 구성된다. 축 A(환경 유형)는 위의 fine-tuned 3-class 모델이 담당하여 기준 소음을 설정하고, 축 B(실시간 방해 판정)는 AudioSet 527 클래스로 사전학습된 PANNs CNN10 을 함께 적재하여 소리의 '종류'를 식별한다. 축 B 는 키보드 타건음·타이핑·마우스·볼펜 클릭·필기음·종이(책장) 넘김 등 학습 행위에 수반되는 '학습 이벤트 소리'와, 말소리(대화·외침)·사이렌·경보·유리 깨짐 등 '방해음'을 구분한다. 클라이언트가 약 2 초 간격으로 누적 오디오를 16 kHz WAV 로 인코딩하여 전송하면 서버가 두 모델을 실행하고, 학습 이벤트 소리로 판정되면 데시벨이 높더라도 방해로 보지 않는다. 이로써 키보드 타이핑만으로 집중 저하로 잘못 판단되던 문제를 해소하였다.

DCASE TUT Acoustic Scenes 2016 의 15 개 음향 장면 중 이동수단과 순수 자연환경을 제외하고, 학습 맥락과 관련된 장면을 quiet(library, home), social_indoor(cafe/restaurant, office, grocery store), outdoor(city center, residential area, park)의 3 개 클래스로 매핑하였다. 공식 fold1 분할(녹음 위치 기반, 데이터 누수 없음)을 사용하여 학습 468 개, 검증 156 개를 구성하였다. AudioSet 사전학습 백본을 동결한 채 분류 헤드를 학습하다가 10 번째 에포크에서 마지막 두 합성곱 블록을 해제하고 학습률을 1/10 로 낮추어 미세조정하였으며, 클래스 불균형은 역빈도 가중치로 보정하였다. 학습 진행 상황(에포크별 손실·정확도)을 기록한 학습 로그는 아래와 같다.

▶ PANNs 환경을 분류 학습 로그 (에포크별)

클래스별 학습 샘플 수: [113, 178, 177] → 가중치: [1.3805309534072876, 0.8764045238494873, 0.8813559412956238]

Epoch [1/30] Loss: 1.0487 Train Acc: 0.4487 Val Acc: 0.2564

-> Saved best model (val_acc: 0.2564)

Epoch [2/30] Loss: 0.8764 Train Acc: 0.6624 Val Acc: 0.4551

-> Saved best model (val_acc: 0.4551)

Epoch [3/30] Loss: 0.7536 Train Acc: 0.6752 Val Acc: 0.7949

-> Saved best model (val_acc: 0.7949)

Epoch [4/30] Loss: 0.7390 Train Acc: 0.6774 Val Acc: 0.7692

Epoch [5/30] Loss: 0.6611 Train Acc: 0.7521 Val Acc: 0.7821

Epoch [6/30] Loss: 0.6119 Train Acc: 0.7436 Val Acc: 0.8205

-> Saved best model (val_acc: 0.8205)

Epoch [7/30] Loss: 0.6555 Train Acc: 0.7265 Val Acc: 0.8141

Epoch [8/30] Loss: 0.5874 Train Acc: 0.7692 Val Acc: 0.8205

Epoch [9/30] Loss: 0.5880 Train Acc: 0.7500 Val Acc: 0.7949

Epoch [10/30] Loss: 0.6231 Train Acc: 0.7158 Val Acc: 0.8526

-> Saved best model (val_acc: 0.8526)

Epoch 10: Unfreezing PANNs conv blocks for fine-tuning

Epoch [11/30] Loss: 0.5505 Train Acc: 0.7671 Val Acc: 0.8077

Epoch [12/30] Loss: 0.5815 Train Acc: 0.7564 Val Acc: 0.8333

Epoch [13/30] Loss: 0.5177 Train Acc: 0.7671 Val Acc: 0.8269

.....(생략).....

Epoch [28/30] Loss: 0.5477 Train Acc: 0.7778 Val Acc: 0.8077

Epoch [29/30] Loss: 0.5030 Train Acc: 0.7778 Val Acc: 0.8333

Epoch [30/30] Loss: 0.5144 Train Acc: 0.7756 Val Acc: 0.8077

Training complete. Best Val Acc: 0.8526

검증 집합 전체에 대한 최종 성능은 정확도 0.8269, Macro-F1 0.8127 이며, 클래스별 정밀도/재현율/F1 은 아래와 같다.

클래스	Precision	Recall	F1
quiet	0.7941	0.6279	0.7013
social_indoor	0.7581	0.8393	0.7966
outdoor	0.9167	0.9649	0.9402
전체 (Accuracy / Macro-F1)	—	—	0.8269 / 0.8127

성능 저하의 대부분은 quiet 와 social_indoor(둘 다 실내) 사이에서 발생하였다. 이는 '실내가 조용한가'의 판단이 환경 유형 자체보다는 실시간 말소리 유무에 더 의존한다는 것을 보여준다고 볼 수 있으며, 환경 분류는 기준 소음을 설정하는 용도로 활용하고 실시간 방해 판정은 말소리-돌발음으로 보강하는 방식으로 구성한 것으로 보강하고 있으므로 문제가 없다고 판단한다.

7. 단계별 세부 설명 및 알고리즘

본 시스템은 집중 모드 실행, 초기 보정(Calibration), 학습환경 적응, 실시간 집중도 파악(계층적 판단), 종료(결과 리포트)의 4 단계적 구조로 동작한다. 각 단계는 독립적 기능을 수행하면서도 연속적으로 연결되어 전체 흐름을 구성한다.

7.1 집중 모드 실행과 초기 Calibration

사용자가 집중 모드를 시작하면 측정 중 디바이스 사용 제한, 초기 적응 구간에는 집중 시간이 누적되지 않는다는 점, 얼굴 미검출이 지속되면 자동 종료될 수 있다는 점을 안내한 뒤 캘리브레이션 단계로 진입한다. 캘리브레이션은 사용자마다 다른 카메라 위치와 자세를 보정하기 위한 단계로, 화면 중앙에 표시되는 얼굴 윤곽 가이드에 사용자가 얼굴을 맞추면 약 5 초의 준비 시간을 거쳐 보정을 수행한다. 보정 과정에서는 L2CS-Net 이 출력하는 yaw/pitch 의 중앙값을 개인별 '정면 원점'으로 기록한다. 이는 웹캠이 보통 눈높이보다 위에 있어 정면을 응시해도 수직 방향에 일정한 치우침(bias)이 생기는 문제를 제거하기 위함이며, 평균이 아닌 중앙값을 사용하여 순간적인 이상치에 강건(Robust)하도록 하였다. 동시에 고개 각도(Head Pose)의 pitch 기준값도 함께 기록하여, 모델이 상방 시선의 출력을 압축하는 경향을 보조적으로 보완하는 데 사용한다.

구현 관점에서 캘리브레이션의 핵심은 '개인 원점 보정'이다. calibrating 단계(약 15 초) 동안 클라이언트는 서버 L2CS-Net 이 반환하는 시선 각도 표본 $\{yaw_i, pitch_i\}$ 와 MediaPipe 로 계산한 고개 각도 표본 $\{headPitch_i\}$ 를 누적한다. 단계가 끝나면 각 표본의 중앙값(median)을 개인 원점으로 확정한다. 즉 원점은 다음과 같이 정의된다.

```
yaw0 = median(yawi), pitch0 = median(pitchi), headPitch0 = median(headPitchi)
```

이후 매 프레임의 시선 화면 좌표 (x, y)는 원점을 차감한 상대 각도로부터 다음과 같이 계산한다(static/index.html 의 computeGazePoint, finalizeCalibration 함수에 해당). 수평은 보정된 yaw 를, 수직은 보정된 pitch 와 고개 각도를 함께 사용한다. 특히 L2CS-Net 이 상방(위)에서 출력을 압축하는 경향이 있어, 위쪽(pitch>0)에서는 더 큰 민감도(분모 22)를, 아래쪽에서는 완만한 민감도(분모 36)를 적용하고 고개 각도 항을 더해 실제 활용에서는 이 점을 보완한다.

```
yaw' = yaw - yaw0, pitch' = pitch - pitch0, headPitch' = headPitch - headPitch0
x = clip(0.5 + yaw'/70, 0, 1)
y = clip(0.5 - pitch'/(pitch'>0 ? 22 : 36) + headPitch'/28, 0, 1)
```


중앙값을 사용하는 이유는 캘리브레이션 도중 발생하는 순간적 이상치(깜빡임, 미세한 자세 변화)에 평균보다 강건하기 때문이다. 또한 저조도 영상 보정(CLAHE)을 구현하여 적용하였다. 서버는 시선 추정용 얼굴 크롭과 휴대폰 탐지용 프레임을 디코딩한 뒤, 이미지를 LAB 색공간으로 변환하여 명도(L) 채널에만 CLAHE(`clipLimit=2.0, tileGridSize=8x8`)를 적용한다(`backend/app/image_utils.py`). 이때 L 채널 평균 밝기가 임계값(110) 이상인 '충분히 밝은' 이미지는 보정을 건너뛰는 적응형 방식을 사용하여, 정상 조명에서는 원본을 보존하고 저조도에서만 대비를 개선한다. 색은 보존하고 명도 대비만 향상시키므로 어두운 환경에서도 랜드마크·시선·객체 탐지의 안정성이 높아지게 된다.

7.2 학습환경 적응 — I-DT, KDE, 연결요소

적응 단계에서는 약 3 분 동안 사용자의 시선 분포와 주변 소음을 분석하여 개인화된 기준을 생성한다. 학습 Zone 생성은 세 단계의 알고리즘으로 이루어진다. 첫째, I-DT(Dispersion-Threshold) 알고리즘으로 실제 응시(fixation)와 이동(saccade)을 분리한다. 일정 시간 이상 분산이 임계값 이하로 유지되는 구간만 응시로 인정하고, 시선이 빠르게 이동하는 동안의 좌표는 노이즈로 간주하여 제거한다. 둘째, 검출된 각 응시점에 그 지속 시간을 가중치로 한 가우시안 커널을 누적하여 '어디를 얼마나 오래 보았는가'를 나타내는 밀도 지도(64×48 격자의 형태)를 만든다. 이것이 곧 응시 시간 가중 커널 밀도 추정(KDE)이다. 셋째, 전체 밀도의 일정 비율(기본 92%)을 덮는 고밀도 영역을 임계화하고, 서로 연결된 영역(`connected components`)을 각각 하나의 학습 Zone 으로 정의한다.

이 방식은 학습 도구의 개수를 사전에 알 필요가 없고(영역 개수가 자동으로 결정됨), 노트북 화면이나 책처럼 임의 형태의 응시 영역을 그대로 포착하며, '자주·오래 응시한 곳에 학습 대상이 존재한다'는 가정을 직접 반영한다. 또한 결과가 픽셀 마스크 형태로 산출되므로 이후 평가방식인 IoU 평가와 히트맵 시각화에 그대로 활용할 수 있다. 적응 단계의 길이인 3 분은 예비값으로, I-DT 응시점이 충분히 누적되고 단주기 소음 변동을 어느 정도 평균화하기에는 합리적인 출발점이지만, 카페처럼 소음이 가변적인 환경에서는 3 분 샘플의 대표성이 부족할 수 있어 추후 실험을 통해 최적화할 필요가 있다. 적응 단계는 30 분 간격으로 자동 반복되며, 사용자가 학습 도구 위치를 바꾼 경우에는 '적응' 버튼으로 직접 재적응을 요청할 수도 있다. 이때 측정은 잠시 멈추지만 그때까지 누적된 집중 점수는 그대로 유지되며 재적응이 끝나면 이어서 측정한다.

이 파이프라인의 수식과 파라미터는 backend/app/services/learning_zone.py 에 구현되어 있으며, 각 단계는 다음과 같이 정식화된다.

(1) I-DT 응시 검출. 시간순 시선 좌표열에서 연속 구간 $[i, j]$ 를 확장하며, 그 구간의 분산을 좌표 범위의 합으로 정의한다. 분산이 임계값 $IDT_DISPERSION(=0.12)$ 이하를 유지하는 한 구간을 키우고, 그 구간의 지속 시간이 $IDT_MIN_DURATION(=0.10 \text{ 초})$ 이상이며 표본이 $IDT_MIN_POINTS(=2)$ 이상이면 하나의 응시(fixation)로 인정한다.

```
dispersion = (max x - min x) + (max y - min y) ≤ 0.12 → 같은 fixation
fixation = (중심  $\bar{x}$ , 중심  $\bar{y}$ , 지속시간 d)
```

(2) 응시시간 가중 KDE. 64×48 격자의 각 점 (gx, gy) 에서, 모든 응시점에 대해 지속시간 d 를 가중치로 한 가우시안 커널을 누적하여 밀도 D 를 계산한다(커널 폭 $\sigma = KDE_BANDWIDTH = 0.10$).

$$D(gx, gy) = \sum_k d_k \cdot \exp(-[(gx - \bar{x}_k)^2 + (gy - \bar{y}_k)^2] / (2\sigma^2)), \quad \sigma = 0.10$$

(3) 레벨셋 임계화. 전체 밀도의 일정 비율 $MASS_COVERAGE(=0.92)$ 를 포함하는 최소 밀도 레벨 τ 를 찾는다. 즉 밀도를 내림차순 정렬한 누적합이 전체의 92%에 도달하는 지점의 밀도를 임계값으로 삼아, $D \geq \tau$ 인 격자를 학습 영역 후보로 한다.

(4) 연결요소 추출. 임계화된 이진 마스크에 대해 연결요소(scipy.ndimage.label)를 구하고, $MIN_ZONE_CELLS(=5)$ 미만의 작은 덩어리는 제거한 뒤 남은 각 덩어리를 하나의 학습 Zone으로 정의한다. 마지막으로 경계를 $MASK_DILATION_ITERS(=5)$ 회 팽창시켜 모니터 가장자리.키보드처럼 인접한 응시 영역까지 포용한다. 실시간 판정에서 어떤 시선 좌표 (gx, gy) 의 학습 Zone 포함 여부는 해당 격자 셀의 마스크 값으로 즉시 결정된다.

7.3 실시간 집중도 파악 — 계층적 판단 모델

실시간 집중도 파악은 단일 분류기로 한 번에 판정하는 대신, 판단 기준이 명확한 단서부터 순차적으로 검사하는 계층적 판단 모델(Hierarchical Decision Model)로 구현하였다. 상위 계층은 집중 저하의 근거가 비교적 명확하고 잘못 판단할 가능성이 낮으므로, 상위 계층에서 결정되면 즉시 등급을 부여한다. 계층의 구성과 각 계층의 판정 근거는 다음과 같다.

계층	판단 대상	근거 모델	결과 등급
1	얼굴 검출(자리 이탈)	MediaPipe	장시간 미검출 → F, 자동 종료
2	줄음/수면(EAR), 하품(MAR)	랜드마크 수식	줄음 C / 수면 F / 하품 B

3	휴대폰 사용	YOLOv8 듀얼	검출 시 C
4-1	시선 이탈(학습 Zone 밖)	L2CS + KDE Zone	지속 정도에 따라 B~C
4-2	주변 소음 방해	PANNs + dB	기준 초과/말소리 시 B~C

매 프레임의 상태는 A(집중)·B(저하)·C(산만)·F(이탈/수면)의 4 등급으로 판정한다. 각 등급에는 감점이 부여되며(A=0, B=1, C=3, F=10), 이를 전체 프레임에 걸쳐 누적하여 최종 집중 점수를 다음과 같이 산출한다.

$$\text{최종 집중 점수} = \max(0, 100 - (\text{누적 감점} / \text{전체 프레임 수}) \times 100)$$

이 감점 체계는 집중을 방해하는 정도가 클수록 더 큰 가중치를 부여하도록 설계되었다. A는 감점이 없고, 일시적 저하(B)에는 작은 감점, 명확한 산만(C)에는 중간 감점, 자리 이탈·수면(F)에는 큰 감점을 부여하여 등급 간 상대적 심각도를 점수에 반영한다. 수면이나 자리 이탈 등 F 상태가 일정 시간 지속되면 사용자에게 경고를 표시한 뒤 30 초의 유예를 거쳐 자동 종료한다.

구현 관점에서 계층적 판단은 backend/app/services/concentration.py 의 evaluate() 함수가 매 프레임 수행한다. 각 계층은 '조건 충족 시 등급을 부여하고 즉시 반환(early return)'하는 구조로, 상위 계층에서 결정되면 하위 계층을 평가하지 않는다. 판단에 쓰이는 두 핵심 수식 EAR·MAR 은 다음과 같이 정의된다(p는 랜드마크 좌표).

$$\begin{aligned} \text{EAR} &= (\|p_{\text{top1}} - p_{\text{bot1}}\| + \|p_{\text{top2}} - p_{\text{bot2}}\|) / (2 \cdot \|p_{\text{left}} - p_{\text{right}}\|) \\ \text{MAR} &= \|p_{\text{top}} - p_{\text{bot}}\| / \|p_{\text{left}} - p_{\text{right}}\| \end{aligned}$$

프레임 단위 판단 흐름은 다음과 같다(괄호 안은 약 30fps 기준 프레임 임계). 각 단계는 상태(state)에 누적 카운터를 유지하여 '지속 시간'을 판정한다.

- 계층 1 — 얼굴 검출: 얼굴 미검출이면 face_absent_frames 를 증가시키고, 약 5 초(150 프레임) 이상이면 F(자리 이탈), 그 미만은 C(일시 손실)를 부여하고 즉시 반환한다.
- 계층 2 — 졸음/하품: EAR 이 EAR_THRESHOLD(0.21) 미만이면 ear_low_frames 를 증가시켜, 약 10 초(300 프레임) 이상이면 수면(F, 즉시 반환), 약 0.3 초(9 프레임) 이상이면 졸음(C)으로 판정한다. MAR 이 0.6 을 초과해 약 1.5 초(45 프레임) 지속되면 하품(B)을 부여한다.
- 계층 3 — 휴대폰: 휴대폰이 확정 탐지되면 phone_detected_count 를 증가시키고 C 를 부여한 뒤 즉시 반환한다.

- 계층 4-1 — 시선 이탈: 학습 Zone 밖 응시가 약 8 초(240 프레임) 이상 지속되면 C, 약 4 초(120 프레임) 이상이면 B 를 부여한다. Zone 으로 돌아오면 누적 카운터를 빠르게 감소시켜 자연스러운 시선 이동을 오판하지 않는다.
- 계층 4-2 — 소음: 기준 데시벨을 초과하거나 방해성 소리가 감지되면 등급을 한 단계 낮춘다(B~C).

최종적으로 어떤 트리거도 발생하지 않은 프레임만 `focused_frames` 로 집계되고, 각 프레임 등급에 따른 감점($A=0 \cdot B=1 \cdot C=3 \cdot F=10$)이 `penalty_score` 에 누적된다. 세션 종료 시 등급 분포·트리거별 횟수·감점 기여·최종 점수가 요약(`get_session_summary`)으로 산출되며, 이 값들이 결과 화면의 명확한 점수 산출 과정으로 사용자에게 제시된다.

7.4 종료 및 결과 리포트

세션이 종료되면 총 학습 시간, 실질 집중 유지 시간, 집중 비율, 시선 이탈·휴대폰·줄음 감지 횟수, 등급 분포, 최종 집중 점수를 종합한 리포트를 생성한다. 결과 화면은 최종 등급과 100 점 만점 의 점수를 가장 크게 제시하고, 세부 항목은 '상세 결과 보기'로 펼쳐 확인하도록 구성하여 직관성을 높였다. 또한 모든 결과는 브라우저 로컬 스토리지에 저장되어 '기록' 화면에서 다시 확인할 수 있으며, 각 기록이 집중 모드와 개발자 모드 중 어디에서 측정되었는지 구분하여 표시하게 하였다. 학습 환경 적응이 끝나기 전(집중도 측정 단계 진입 전)에 종료된 세션은 점수를 산출하지 않고 '중단'으로 기록한다.

8. 임계값 및 파라미터 결정 근거

본 시스템의 판정에 사용된 주요 임계값과 파라미터는 선행 연구와 신호의 물리적 특성, 사용한 모델의 검증 성능을 근거로 설정하였다. 각 값의 결정 근거는 다음과 같다.

8.1 졸음·하품 관련 임계값

EAR 임계값은 0.21로 설정하였다. 이는 눈을 충분히 뜬 상태의 EAR이 약 0.25~0.35인 반면 눈을 감으면 0.1 이하로 떨어진다는 EAR 기반 졸음 탐지 연구의 일반적 관찰과, 본 시스템이 참고한 MediaPipe 기반 졸음 탐지 구현체[12][13]의 관행값에 부합한다. 눈 감김 지속 시간 기준은 사람의 일반적인 자발적 깜빡임이 약 0.1~0.4 초라는 점을 고려하여, 0.3 초 미만은 정상 깜빡임, 0.3 초 이상 지속은 졸음 경향(C 등급), 10 초 이상 지속은 수면(F 등급)으로 구분하였다. MAR 임계값 0.6과 약 1.5 초의 지속 기준은 하품이 통상 1.5~2.5 초간 입을 크게 벌리는 행동이라는 점을 반영한 것으로, 일시적인 발화나 미소와 구분하기 위해 지속 시간 조건을 함께 두었다.

8.2 캘리브레이션·적응 시간

캘리브레이션 단계는 약 15 초로 설정하였다. 시선 추정이 초당 약 5 회 갱신되므로 15 초 동안 약 75 개의 표본이 수집되며, 이는 원점의 중앙값을 안정적으로 추정하기에 충분하다. 학습환경 적응 단계는 3 분으로 설정하였는데, 이는 7.2 절에서 설명한 바와 같이 I-DT 응시점이 충분히 누적되고 소음의 단주기 변동을 평균화하기 위한 예비값이다. 다만 가변 소음 환경에서의 대표성 한계가 있으므로, 적응 시간은 추후 실험을 통해 환경별로 최적화되어야 할 것이다. 재적응 주기 30 분은 학습 도중 도구 배치나 자세가 점진적으로 변할 수 있음을 고려한 것이며, 사용자가 명시적으로 도구를 추가한 경우에는 수동 재적응으로 즉시 반영할 수 있게 하였다.

8.3 학습 Zone(KDE) 파라미터

KDE의 커널 폭(bandwidth)은 0.10으로 설정하였다. L2CS-Net의 평균 각도 오차가 약 8.8°인 점과 일반적인 모니터가 화면에서 차지하는 폭을 함께 고려하면, 측정 불확실성과 모니터 영역을 동시에 포용하기 위한 적절한 규모가 정규화 좌표상 약 0.1이다. 학습 영역의 질량 커버리지는 92%로 두어 응시 분포의 대부분을 학습 영역으로 인정하되 극단적 이상치는 제외하도록 하였고, 경계 팽창(dilation)을 5 회 적용하여 모니터 가장자리나 키보드처럼 본 영역에 인접한 응시까지

자연스럽게 흡수하도록 하였다. 이 설정은 사용자가 큰 모니터의 가장자리를 보거나 키보드를 칠 때 시선 이탈로 오판되던 문제를 해소하기 위한 것이다. 이러한 값의 설정은 반복적으로 수치를 바꿔가며 실험적으로 얻게 된 수치를 적용한 것이다.

8.4 시선 이탈·휴대폰 판정 파라미터

시선 이탈 판정은 학습 Zone 밖 응시가 약 4 초 이상 지속될 때 B 등급, 약 8 초 이상 지속될 때 C 등급을 부여하도록 비교적 관대하게 설정하였다. 이는 키보드를 보거나 필기를 하는 등 학습 중 자연스럽게 발생하는 짧은 시선 이동을 집중 저하로 오판하지 않기 위함이며, 짧게 Zone으로 돌아오면 누적이 빠르게 회복되도록 하였다. 휴대폰 탐지는 약 0.8 초 간격으로 프레임을 분석하여 빠른 처리 속도를 확보하되, 신뢰도 임계값 0.35와 '최근 3 회 중 2 회 이상 검출'이라는 시간적인 디바운스를 함께 적용하여 응답성과 오탐 억제 사이의 균형을 맞추었다.

9. 성능 평가 체계 및 가중치 결정

본 시스템은 단일 분류 정확도가 아니라, 사용자 환경을 이해하는 '환경 적응 성능(E)'과 실시간으로 집중 상태를 판단하는 '실시간 집중도 파악 성능(rtC)'이라는 두 축으로 평가한다. 두 축은 시사하는 바가 다르므로 단일 점수로 합산하지 않고 각각 독립적으로 해석한다. 각 종합 지표는 세부 성능의 가중 평균으로 정의되며, 본 장에서는 그 가중치를 근거와 함께 확정한다.

9.1 환경 적응 종합 성능 E 와 가중치 α

환경 적응 성능은 시선 방향 적응 성능 E_{gaze} (학습 Zone 과 실제 학습 영역의 IoU)와 소음 환경 적응 성능 E_{audio} (환경 분류 Accuracy-Macro-F1)의 가중 평균으로 정의한다.

$$E_{\text{total}} = \alpha \cdot E_{\text{gaze}} + (1 - \alpha) \cdot E_{\text{audio}}$$

가중치 α 는 0.7 로 확정한다. 그 근거는 다음 세 가지이다.

- 기능적 위계: 시선 적응이 생성하는 학습 Zone 은 이후 모든 시선 이탈 판정의 '기준 좌표계'가 되어 실시간 집중도 파악의 핵심 계층(4-1)을 직접 좌우한다. 반면 소음 적응은 기준 데시벨을 설정하는 변조(modulation) 역할에 그치며 상위 계층(얼굴·줄음·휴대폰)의 판정에는 관여하지 않는다. 즉 두 모달리티의 시스템 기여도는 대등하지 않고 시선이 주도적인 판단 기준이 된다.
- 설계 원칙과의 정합성: 본 시스템은 2.2 절에서 영상을 주 모달리티로, 오디오를 보조 모달리티로 명시적으로 규정하였다(무관한 말소리 효과에 근거). 가중치는 이 설계 원칙을 수치로 반영해야 한다고 판단 하였다.
- 후기 융합(late fusion)의 관례: 멀티모달 학습에서 주/보조 모달리티를 가중 결합할 때, 보조 모달리티의 기여를 0.2~0.3 수준으로 두는 것이 일반적이다. 이는 보조 신호가 주 신호를 보완하되 지배하지 않도록 하기 위함이다. 이에 따라 0.3 을 오디오에 부여하여 보조 모달리티의 기여를 충분히 인정하되 시선에 우위를 유지하도록 하였다. 이는 중간 보고서에서 잠정 제시한 0.6~0.7 범위와도 부합한다.

이러한 이유로 시선에 0.7, 소음에 0.3 을 부여한다. 그러나 이 값은 여전히 점정적 값에 그친 설계 값이며 실험을 통해 더욱 정교히 변환해야할 것으로 판단된다.

9.2 실시간 집중도 종합 성능 rtc와 가중치 β

실시간 집중도 파악 성능은 계층적 판단을 구성하는 다섯 세부 기능의 성능을 가중 평균하여 정의한다. 각 세부 기능의 대표 성능 지표는 과제 특성에 맞추어 얼굴 탐지·휴대폰 탐지에는 AP(보조: Precision/Recall), 졸음·소음 분류에는 Accuracy(보조: Macro-F1)를 사용한다.

$$\text{rtc_total} = \beta_1 \cdot P_{\text{face}} + \beta_2 \cdot P_{\text{drowsy}} + \beta_3 \cdot P_{\text{phone}} + \beta_4 \cdot P_{\text{gaze}} + \beta_5 \cdot P_{\text{noise}} \\ (\beta_1 + \beta_2 + \beta_3 + \beta_4 + \beta_5 = 1)$$

가중치는 각 기능이 집중도 판정에서 갖는 결정성(계층 순위)과 신뢰도, 집중에 미치는 영향의 직접성을 기준으로 배분한다. 계층적 판단 모델에서 상위 계층일수록 집중 저하의 근거가 명확하고 잘못 된 판단을 할 가능성이 낮으므로 더 큰 가중치를 부여하는 것이 타당하다. 구체적으로 살펴보면, 얼굴 탐지는 측정 가능 여부 자체를 좌우하고 자리 이탈이라는 가장 결정적인 F 등급을 유발하므로 가장 높은 가중치를 부여한다. 졸음·수면 판정 또한 EAR이라는 검증된 지표에 기반하고 집중과의 관련성이 직접적이며 역시 F/C 등급을 유발하므로 높은 가중치를 둔다. 휴대폰은 명확한 방해 요소이고 탐지 신뢰도가 높으나 C 등급에 해당하여 중간 가중치를, 시선 이탈은 집중과의 관련은 높지만 학습 Zone 정확도에 의존하여 상대적으로 노이즈가 있으므로 중간 가중치를 부여한다. 소음은 보조 모달리티로서 가장 낮은 가중치를 둔다. 이상의 원칙에 따라 가중치를 다음과 같이 확정한다.

세부 기능	등급 영향	신뢰도/결정성	가중치
얼굴 탐지(자리 이탈)	F (자동 종료)	매우 높음	$\beta_1 = 0.25$
졸음/수면(EAR·MAR)	F / C / B	높음	$\beta_2 = 0.25$
휴대폰 탐지	C	중간	$\beta_3 = 0.20$
시선 이탈	B~C	중간	$\beta_4 = 0.20$
주변 소음	B~C (보조)	보조	$\beta_5 = 0.10$

이러한 근거로 종합 성능 가중치를 확정하였다. 다만 이 값은 여전히 점정적 값에 그친 설계 값이며 향후 실사용자 데이터가 축적되면 각 기능의 실제 기여도를 반영하여 재조정할 수 있을 것으로 판단된다.

10. 성능 평가


개별 모델의 전이학습 결과는 6 장(6.3~6.5 절)에서 보고하였다. 본 장에서는 9 장에서 확정한 평가 체계(E_{total} , rtC_{total})와 가중치에 따라 시스템 수준의 성능을 측정한 결과를 보고한다. 다만 본 프로젝트는 학부 기말 과제라는 시간 제약과 주변 환경 여건의 한계 속에서 수행되었다. 시스템 수준의 정량 평가를 엄밀히 수행하려면 다수의 피실험자를 섭외하고, 독서실·카페·강의실 등 다양한 학습 환경과 여러 종류의 전자기기·학습도구를 확보하며, 조명·카메라 위치·사용자별 자세 등 수많은 실험 변수를 통제해야 한다. 그러나 이러한 조건을 모두 갖추기는 현실적으로 어려웠고, 통제되지 않은 환경에서 얻은 값은 신뢰하기 어렵다. 이에 본 보고서는 (1) 시선 생성기를 통한 통제된 합성 실험으로 체계적·재현 가능한 정량 평가를 수행하고, (2) 직접 수행한 소수의 실제 학습 세션 캡처로 이를 보강하는 하이브리드 방식을 채택하였다. 두 결과를 함께 제시하여 통제성과 현실성을 모두 확보하고자 하였다.

10.1 환경 적응도 평가


시선 방향 적응 성능 E_{gaze} 는 시스템이 생성한 학습 Zone 과 실제 학습 영역(Ground Truth)의 IoU 로 평가하며, 보조 지표로 Dice 와 학습영역 포함률(Recall)을 사용한다(9.1 절). 먼저 직접 수행한 실제 학습 세션 3 건을 개발자 모드로 캡처하여, 시스템이 생성한 학습 Zone(화면의 Zone 박스)과 실제 학습대상이 차지하는 시선영역을 비교하였다. 세 세션은 각각 (S1) 정면 모니터+키보드, (S2) 좌측 독서대+하단 책+중앙 강의화면, (S3) 단일 모니터 응시 환경이며, 결과는 다음과 같다.

실험 세션	Zone 수	IoU	Dice	학습영역 포함률(Recall)
S1 정면 모니터+키보드	2	0.556	0.715	0.952
S2 독서대+책+강의화면	3	0.748	0.856	1.000
S3 단일 모니터	1	0.594	0.745	1.000
평균	—	0.633	0.772	0.984


그림 5. 실제 학습 세션의 학습 Zone 검출 결과 (주황 박스 = 시스템이 생성한 학습 Zone)



(S1) 정면 모니터+키보드 — 모니터·키보드 2 개 Zone 검출



(S2) 좌측 독서대+하단 책+중앙 강의화면 — 3 개 Zone 분리 검출



(S3) 단일 모니터 — 1 개 Zone 검출

세 세션 모두 시스템이 학습 대상의 개수와 배치를 정확히 포착하였다. S1에서는 모니터와 키보드 2개, S2에서는 독서대·책·강의화면 3개, S3에서는 단일 모니터 1개의 Zone을 형성하여 사용자가 실제로 응시한 학습도구 구성과 일치하였다. 정량적으로는 평균 IoU 0.633, Dice 0.772이며 학습영역 포함률(Recall)이 평균 0.984로, 실제 학습 영역의 대부분을 학습 Zone이 포함함을 확인하였다. 특히 측면 독서대와 하단 책을 별도 Zone으로 분리한 S2(IoU 0.748)는, 정면 응시만을 집중으로 보는 기존 방식과 달리 측면·하단 학습도구를 정상 학습 영역으로 포용하는 본 시스템의 핵심 차별점을 실제 환경에서 입증한 사례이다. 다만 본 실측은 1인의 3개 세션으로 한정되고 Ground Truth가 수작업 표기라는 점에서 사례 검증 성격임을 명시한다.

실측 표본 수의 한계를 보완하기 위해, 통제된 합성 시선 데이터로 동일 지표를 재현 가능하게 측정하였다(backend/eval_zone_iou.py). 대표 학습 환경을 모사한 시선열에 대해 실제 학습 영역을 사각형 Ground Truth로 정의하고 시스템 Zone 마스크와 비교한 결과는 다음과 같다.

합성 시나리오	IoU	Dice	Recall	영역 밖 제외율(Spec.)
노트북(중앙 모니터)	0.233	0.378	1.000	0.595
독서대(모니터+책)	0.254	0.406	1.000	0.442
넓은 모니터(가로 와이드)	0.305	0.467	1.000	0.481
평균	0.264	0.417	1.000	0.506

합성 실험에서는 평균 IoU 0.264로 실측보다 낮게 나타났는데, 이는 합성 Ground Truth를 응시 발생 지점에 밀착하여 좁게 정의한 반면 시스템은 8.3절에서 의도한 여유 마진(KDE bandwidth 0.10, 경계 팽창 5회)으로 Zone을 넓게 형성하기 때문이다. 그럼에도 학습영역 포함률(Recall)이 모든 시나리오에서 1.000으로, 합성·실측 양쪽 모두에서 '실제 학습 시선을 놓치지 않는다'는 보수적 동작 특성이 일관되게 확인된다. 즉 본 시스템의 학습 Zone은 정밀하게 좁히기보다 실제 학습 영역을 빠짐없이 포함하여 거짓 이탈 경보를 줄이는 방향으로 동작한다.

환경을 적응 성능 E_{audio} 는 6.5절의 실측값인 정확도 0.8269, Macro-F1 0.8127을 사용한다. 실사용 환경을 대표하는 실측 평균 IoU($E_{\text{gaze}} = 0.633$)와 E_{audio} 를 9.1절에서 확정한 가중치 $\alpha=0.7$ 로 결합하면 $E_{\text{total}} = 0.7 \times 0.633 + 0.3 \times 0.8269 = 0.691$ 이다. 표본 수가 늘어나면 본 값은 갱신될 수 있다.

10.2 실시간 집중도 평가

실시간 집중도 rtC_{total} 은 계층적 판단을 구성하는 다섯 세부 기능의 성능을 9.2 절의 가중치 β 로 가중 평균하여 정의한다. 각 기능을 구성하는 모델의 실측·인용 성능은 6장에서 보고한 값으로, 이를 한데 모으면 다음과 같다.

세부 기능(계층)	근거 모델	대표 지표	실측값	비고
얼굴 검출(계층 1)	MediaPipe Face Mesh	검출 신뢰도	검증된 사전모델	규칙 기반, 별도 정량셋 미측정
줄음/하품(계층 2)	EAR/MAR 수식	임계 판정	규칙 기반	8.1 절 임계 근거, 별도 정량셋 미측정
휴대폰(계층 3)	YOLOv8n 듀얼	mAP@0.5	0.855	mAP.5:.95 0.678 / P 0.811 / R 0.804 (6.4)
시선 이탈(계층 4-1)	L2CS-Net + KDE	MAE(°)	8.8°	목표 < 10° 달성, 인용(6.3)
주변 소음(계층 4-2)	PANNs 3-class	Acc / Macro-F1	0.8269 / 0.8127	(6.5)

휴대폰 탐지(mAP 0.855), 환경음 분류(정확도 0.8269), 시선 추정(MAE 8.8°)은 검증 집합에 대한 실측·인용 성능을 그대로 확보하였다. 반면 얼굴 검출과 줄음/하품 판정은 검증된 사전학습 모델(MediaPipe)과 선행 연구 기반 임계값 수식(8.1 절)에 근거하므로 별도의 정량 데이터셋 측정은 수행하지 않았다. 또한 개별 모델 단위 성능과 달리, 다섯 계층이 결합된 '시스템 수준'의 프레임별 등급 정확도(rtC_{total})는 사람이 프레임 단위로 정답을 라벨링한 검증 세션 영상이 있어야 산출할 수 있는데, 이는 10 장 서두에서 밝힌 환경·시간 제약으로 본 프로젝트에서 수행하지 못하였다. 따라서 본 절에서는 구성 모델별 실측 성능을 근거로 제시하며, 시스템 수준 종합 검증은 12.7 절의 향후 과제로 정리한다.

11. 사용자 시나리오 및 검증 계획

본 시스템은 다양한 실제 학습 환경을 가정하여 설계되었으며, 대표 시나리오는 다음과 같다. 노트북 화면 중심 학습에서는 시선이 화면 중앙에 집중되어 단일 학습 Zone 이 중앙에 형성될 것으로 예상된다. 독서대책 중심 학습에서는 학습 Zone 이 화면 측면에 형성되어 측면 응시를 정상 학습으로 인정하는데, 이는 정면 응시만을 집중으로 보는 기존 방식과의 핵심 차별점이다. 카페 등 소음 환경에서는 환경이 social_indoor 로 분류되고 기준 데시벨이 높게 설정되며, 이후 기준 대비 큰 소리나 말소리가 감지될 때 집중 저하로 판정한다. 졸음·휴대폰 등 방해 행동 시나리오에서는 EAR 지속 하락 시 졸음에서 수면으로, 휴대폰 검출 시 산만으로 판정하고 누적 횟수를 리포트에 기록한다.

위 시나리오에 대한 다수 실사용자 기반의 정량 검증은 시간·환경 여건의 제약으로 본 프로젝트 기간 내에 충분히 수행하지 못하였다. 현재까지 확보한 성능은 10 장에서 보고한 바와 같이 1 인의 실제 세션 3 건 기반 학습 Zone 평가(평균 IoU 0.633, Recall 0.984)와 이를 보완하는 통제된 합성 평가(평균 IoU 0.264), 그리고 구성 모델별 실측 지표(휴대폰 mAP 0.855, 환경음 0.8269/0.8127, 시선 MAE 8.8°)이며, 다수 실사용자 조건에서의 시스템 수준 종합 검증은 향후 과제로 남긴다. 향후 검증은 다음 절차로 진행할 계획이다. 첫째, 실사용자 2~5 명을 대상으로 시나리오별(노트북·독서대·카페·방해행동) 집중 세션을 녹화하고, 적응 단계가 끝난 시점의 학습 Zone 을 캡처하여 10.1 절과 동일한 IoU 방식으로 환경 적응 정확도를 측정한다. 둘째, 각 세션 영상을 프레임(또는 1 초) 단위로 정답 상태(집중/졸음/휴대폰/시선이탈/소음)를 라벨링하고, 시스템 예측과 비교하여 계층별 검출·분류 성능과 9.2 절 가중치 기반 rtC_total 을 산출한다. 셋째, 시나리오별로 학습 Zone 형성의 적절성, 환경 분류 정확도, 방해 행동 검출 재현율을 표로 정리하여 본 장을 갱신한다. 이를 통해 현재 소수 실측·합성·구성 모델 단위로 확보한 성능을 실사용 조건의 시스템 수준 성능으로 확장·검증할 수 있을 것으로 기대한다.

12. 향후 개선 과제

본 시스템은 핵심 기능을 동작 가능한 수준으로 구현하였으나, 실서비스 수준으로 발전하기 위해서는 다음과 같은 추가 연구가 필요하다.

12.1 휴대폰 탐지의 사각지대 한계

카메라는 사용자 주변을 모두 비추지 못하므로 휴대폰 사용이 가능한 사각지대(예: 책상 아래, 카메라 화각 밖)가 무조건적으로 생길 수밖에 없다. 따라서 휴대폰 탐지만으로 휴대폰 사용을 제한하는 방식은 명확한 한계를 가지며, 향후에는 다중 카메라, 손 동작 추정, 시선 자세의 간접적 단서 등 보조 신호를 결합하여 사각지대를 보완하는 방향을 검토할 필요가 있다.

12.2 의미 있는 말소리의 양면성

본 시스템은 의미가 있는 말소리가 집중력을 흐트러뜨린다는 가정(무관한 말소리 효과)을 세우고 집중도를 분석하였다. 그러나 인터넷 강의를 스피커로 켜 놓고 학습하는 상황, 영어 단어를 소리 내어 외우는 상황 등 집중력을 오히려 높여 주는 의미 있는 소리 또한 존재한다. 단순히 '의미 있는 말소리 = 집중 저하'로 판단하는 것은 매우 위험한 기준이므로, 추후에는 LLM 이나 별도의 상황 인식 모델을 통해 그 소리가 학습에 도움이 되는지/방해가 되는지를 맥락에 맞게 판단하는 적응 시스템이 필요할 것으로 보인다.

12.3 동적 학습 Zone 생성

현재는 학습 도구의 위치가 변경되거나 추가·삭제될 때 사용자가 직접 '적응' 버튼을 눌러 갱신하는 형태로 설계되었다. 추후에는 AI 가 스스로 도구 배치 변화를 동적으로 감지하여 학습 Zone 을 실시간으로 재구성하는 방식을 채택할 수 있을 것이다.

12.4 LLM 기반 자연어 결과 리포트

결과 리포트는 현재 등급 기반의 수치화된 점수로 출력되나, 이를 복합적으로 분석하여 글 형식의 리포트로 제공한다면 사용자에게 더욱 도움이 되는 결과가 될 수 있다. 추후에는 LLM 을 활용하여 측정 데이터를 자연어 피드백으로 확장할 수 있을 것이다.

12.5 이어폰·귀마개 착용 Edge Case

이어폰·귀마개 착용 케이스는 시간상 본 프로젝트에서 다루지 못하였다. 노이즈 캔슬링 여부, 음악 청취 여부 등은 주변 소리와 영상만으로 판단하기 어려운 영역으로, 이와 관련해서도 추후 검토해 볼 수 있다.

12.6 학습 이벤트 소리 분류

키보드 타건음 등 학습 행위에 수반되는 소리를 방해음과 구분하는 '학습 이벤트 소리 분류'는 본 프로젝트에서 구현을 완료하였다(6.5 절 참조). AudioSet 527 클래스로 사전학습된 PANNs 를 활용하여 Typing·Computer keyboard·Writing·Clicking·Rustle(종이) 등을 학습 이벤트로, Speech·Siren·Glass 등을 방해음으로 매핑하고, 학습 이벤트로 판정되면 데시벨이 높더라도 방해로 보지 않도록 하였다.

다만 AudioSet 에는 '볼펜 딸깍', '형광펜', '지우개'와 같은 미세 분류가 없어 가장 가까운 상위 클래스(Clicking, Writing, Rustle 등)로 근사 매핑하므로 세밀한 구분에는 한계가 있다. 동일한 '딸깍' 소리라도 맥락에 따라 학습 행위일 수도, 다른 행동일 수도 있으므로, 추후에는 13.2 절에서 언급한 맥락 인식(LLM 기반) 적응과 결합하여 정교화하는 방향으로 성능을 향상시킬 수 있을 것으로 판단한다. 또한 실제 잡음이 섞인 환경에서의 분류 안정성은 향후 실사용자 데이터로 검증·보정해야 할 것이다.

12.7 실측 기반 종합 성능 검증

본 보고서의 성능 평가(10 장)는 통제된 합성 실험과 1 인의 소수 실제 세션(3 건)으로 수행되었다. 이는 다수 피실험자 섭외와 다양한 학습 환경·전자기기 확보, 수많은 실험 변수 통제가 학부 기말 과제의 시간·여건상 현실적으로 어려웠기 때문이며, 향후에는 충분한 실측 데이터를 확보한 뒤 시스템 수준의 종합 성능을 정식으로 평가할 필요가 있다. 구체적으로, 충분한 피실험자와 독서실·카페·강의실 등 다양한 환경, 여러 학습도구·전자기기를 확보하여 실험 변수를 통제된 조건에서 다음을 수행한다. 첫째, 시나리오별로 학습 Zone IoU 를 다수 표본으로 재측정하여 E_gaze 의 신뢰구간을 확보한다. 둘째, 각 세션 영상을 프레임 단위로 라벨링하여 계층별 검출·분류 성능과 9.2 절 가중치 기반 rtC_total 을 실측한다. 셋째, 11 장에서 제시한 사용자 시나리오(노트북·독서대·카페·방해행동)별 정량 검증을 수행하여 학습 Zone 형성의 적절성, 환경 분류 정확도, 방해 행동 검출 재현율을 표로 정리한다. 이러한 '충분한 실제 측정 이후의 시나리오 기반 종합 평가'는 본 프로젝트에서 수행하지 못한 핵심 향후 과제로 남긴다.

13. 프로젝트 마무리

13.1 기대 효과 및 활용 방안

본 시스템은 사용자 환경을 먼저 이해한 뒤 개인화된 기준으로 집중도를 평가한다는 점에서, 정면 응시와 단일 지표에 의존하던 기존 연구와 차별화된다. 이러한 특성은 다음과 같은 사회적·산업적 효과로 이어질 수 있다.

■ 사회적 효과

- 자기주도적 학습 능력 및 올바른 메타인지 형성: 단순 '착석 시간'이 아닌 '집중의 질'을 최초로 수치화하여, 학습자 스스로 방해 요인을 통제하고 효율적인 공부 습관을 기를 수 있도록 유도한다.
- 에듀테크(EduTech) 접근성 격차 해소: 고가의 전용 하드웨어(시선 추적기 등) 없이 일반 PC의 웹캠과 마이크만으로 구동되어, 소득 수준과 무관하게 누구나 고도화된 AI 학습 보조를 받을 수 있는 환경을 제공한다.
- 공교육 인프라 및 교육 복지 강화: 학교, 공공 도서관, Wee 클래스 도입 시 학습 취약 계층의 주의력 결핍 패턴을 조기 파악하여 선제적 개입이 가능한 맞춤형 교육 복지망을 구축할 수 있다.
- 국가 차원의 교육 데이터 플랫폼 기여: 교육부의 '디지털 교육 혁신 방안'에 부합하며, 장기적으로 누적된 익명화된 집중도 데이터를 바탕으로 국가 수준의 학습 환경 개선 정책 수립에 기여할 수 있다.

■ 산업적 효과

- [B2C] 진입 장벽이 낮은 대중적 수익 모델 확보: 수험생·대학생·직장인 등 수백만 명의 잠재 타겟을 대상으로 구독형(Freemium) 비즈니스 모델을 적용하여 초기 사용자 풀(Pool)의 폭발적 확보가 가능하다.
- [B2B] 비대면 교육 플랫폼의 SaaS/API 확장: 인강 업체 및 기업 교육(HRD) 솔루션에 연동하여 수강생의 '실제 몰입도'를 정량 평가하고, 이를 바탕으로 강의 콘텐츠 개선 및 수료율 관리에 직접 활용할 수 있다.
- [B2B] 오프라인 공간 사업의 부가가치 창출: 프리미엄 스터디 카페 및 관리형 독서실 등에 도입하여 '데이터 기반 집중도 보장 공간'이라는 차별화된 서비스를 제공하고, 프리미엄 요금의 명확한 정당화 근거로 활용할 수 있다.

- [B2G] 공공 조달 시장 진입: 비용 효율성이 극대화된 소프트웨어 중심 아키텍처를 강점으로, 스마트 스쿨 구축 및 공공 교육 플랫폼 고도화 사업의 핵심 실증 AI 기술로 납품·연계할 수 있다.

13.2 느낀점 및 마무리

본 프로젝트를 통해 모호한 인간의 인지 상태를 수식과 데이터로 정의하는 '추상성의 정량화' 역량과, 비전·오디오 두 모달리티를 실시간으로 통합하는 멀티모달 설계 역량을 키울 수 있었다. 단일 모델 구현에 익숙한 학부 수준의 접근을 넘어, 사용자 환경에 선제적으로 적응하는 AI 를 기획·설계하는 실무형 AI 엔지니어로 한 단계 성장하는 계기가 되었다.

환경 적응도(E, Environment)와 실시간 집중도(rtC, realtimeConcentration) 산출 수식을 검증하고 QA 를 설계하는 과정에서, 실험 설계 방법론이야말로 AI 모델의 신뢰도를 결정짓는 핵심 역량임을 체득하였다. 이를 통해 AI·데이터 사이언스 분야에 요구되는 수학적 사고력을 기를 수 있었다. 또한 멀티모달 파이프라인 설계부터 GUI 통합에 이르기까지, 데이터 전처리에서 사용자 접점까지 AI 프로젝트 전 주기를 직접 책임지는 풀스택 AI 엔지니어링 역량 역시 함께 키울 수 있었다. 하나의 AI 프로젝트 안에서 여러 기술이 유기적으로 맞물리는 융합 경험은 미래 AI 인재로서 갖추어야 할 역량을 한층 끌어올리는 계기가 되었다.

중간 보고서를 작성하며 여러 선행연구를 조사하던 초기에는, 해당 분야의 연구가 이미 상당히 진척되어 있어 유의미한 결과를 새롭게 도출하기가 쉽지 않을 것으로 보여 프로젝트 진행에 많은 어려움이 따를 것으로 예상했다. 실제로도 예상대로 적지 않은 난관이 있었고, 1 인 프로젝트로 진행한 만큼 AI 의 도움을 받는 것은 불가피한 선택이었다. 이번 프로젝트에서는 ChatGPT Codex, Claude Code 등 다양한 AI 플랫폼을 적극 활용하여 아이디어를 구체화하고 실제 구현으로 이어갈 수 있었다.

특히 구현 과정에서 난관에 부딪힐 때마다 AI 에 막연한 질문을 던지는 데 그치지 않고, 문제 상황과 제약 조건을 구체적으로 설명하며 일종의 '상담'을 진행하였다. 이렇게 얻은 해결책은 단순히 모델의 성능을 끌어올리는 데 그치지 않았다. 제안된 접근의 원리를 따라가다 보면 내가 미처 알지 못했던 개념과 이론을 새롭게 배우게 되는 경우가 많았고, AI 와 함께 문제를 풀어 가는 과정 자체가 곧 새로운 학습의 기회가 되었다. 즉 AI 는 결과물의 완성도를 높이는 도구인 동시에, 나의 지식의 공백을 메워 주는 학습 동반자이기도 하였다.

이번 프로젝트는 단순히 하나의 결과물을 산출하는 데 그치지 않고, 다양한 이론과 기술을 직접 공부하고 고민하며 실질적으로 응용해 보는 경험이었다는 점에서 매우 뜻깊은 시간이었다. 특히

여러 수식을 검토하는 과정에서 미처 알지 못했던 이론들을 새롭게 접하게 되었고, 이것이 다시 이론 학습으로 이어지고 나아가 구현과 실제 사용으로까지 연결되면서 해당 개념을 훨씬 확실하게 이해할 수 있었다. 앞으로 새로운 프로젝트를 수행할 때에도, 이번 경험을 발판 삼아 어려운 과정을 만나더라도 이를 극복하고 다양한 아이디어를 적극적으로 시도하며 문제를 헤쳐나갈 수 있으리라 생각한다.

14. 참고문헌

- [1] '남이 봐야 공부 잘 된다?'...캠스터디 열풍, AI Times.
- [2] Robal, T., Zhao, Y., Lofi, C., & Hauff, C. (2018). Webcam-based attention tracking in online learning: A feasibility study. *IUI 2018*, 189–197.
- [3] Hutt, S., Wong, A., Papoutsaki, A. et al. (2024). Webcam-based eye tracking to detect mind wandering and comprehension errors. *Behavior Research Methods*, 56, 1–17.
- [4] 서정민, 박상근. (2024). 시선 트래킹 기반 이러닝 집중도 측정 시스템. 한국정보과학회 학술발표논문집.
- [5] 김희민, 전성국, 김운용, 윤정록. (2022). 한국정보처리학회 추계학술발표대회, 275–276.
- [6] 이문환, 이혁민, 정성택. (2021). 학습자 히스토리를 활용한 녹화 영상 기반 수업 지원 시스템. *Archives of Design Research*, 34(4), 225–239.
- [7] Tobii. <https://www.tobii.com/>
- [8] 이동원, 박상인, 황민철. (2018). 심전도를 이용한 집중도 인식 방법. *한국콘텐츠학회 논문지*, 18(2), 370–377.
- [9] Irrelevant speech effect. Wikipedia.
- [10] Small object detection 을 위한 이미지 데이터. AI Hub (dataSetSn=476).
- [11] DCASE 2016 — TUT Acoustic Scenes 2016.
- [12] Drowsiness-Detection-Mediapipe. GitHub (Tandon-A). (<https://github.com/Tandon-A/Drowsiness-Detection-Mediapipe>)
- [13] Driver Drowsiness Detection Using Mediapipe. LearnOpenCV. (<https://learnopencv.com/driver-drowsiness-detection-using-mediapipe-in-python/>)
- [14] Abdelrahman, A. A. et al. (2022). L2CS-Net: Fine-Grained Gaze Estimation in Unconstrained Environments.
- [15] Kong, Q. et al. (2020). PANNs: Large-Scale Pretrained Audio Neural Networks for Audio Pattern Recognition. *IEEE/ACM TASLP*.
- [16] Jocher, G. et al. Ultralytics YOLOv8.
- [17] 디스플레이 중심 안구 움직임 영상 데이터 — AI 모델 테스트 결과서(L2CS-Net, RIT-Net, Former-DFER). 2022.